

从“垂域推理模型”向“经营智能体”的演进路线说明

当我们谈AI大模型时我们谈些什么？

1. AI的发展历程

AI的概念不是从LLM开始的，LLM只是让AI具备了极大的通用性，并且更重要的是——无论是它的学习模式还是交互模式，都更接近“人”的思维范式，所以大众很多时候已经模糊了LLM和AI之间的“包含”关系——**LLM属于AI，是AI技术在自然语言处理（NLP）方向上的一种具体实现形式。**

所以，我们看到“AI大模型”的时候，作为算法专业同学，应该清楚它可能是Stable Diffusion这样的text-to-image model，可能是BLIP-2这样的image-to-text model，可能是MQTransformer这种做时序预测的decoder-encoder attention model，可能是Pangu这种做天气预测的Swin Transformer model，可能是Qwen3这种Large Language Model，也可能是BERT这种encoder-only model.....“大模型”在算法概念上更强调的是：不同于以往统计学习那套重特征分析、变量交叉、目标函数设计的模型训练模式，而是**以大规模预训练为核心、具有较大参数量和较强任务泛化性的深度学习模型。**

下图的AI算法的发展历程：




Fig. 2. Exploring the Evolution of Artificial Intelligence: A Timeline of Key Innovations and Milestones. It starts from the birth of symbolic and connectionist AI in the 1950s, through key milestones like the AI debates of the 1980s and the advancement in machine learning in the 1990s. This figure highlights significant developments such as the impact of AlexNet on image recognition, the transformation in NLP by models like BERT and GPT, and the rise of generative AI, culminating in the use of LLMs and Agents for autonomous decision-making in the 2020s.

2. 符号主义和链接主义定义下的AI

AI的实现形式可以简单的划分为2种：

1. 符号主义 (Symbolic)
2. 联结主义 (Connectionist)

符号主义 即通过显式的符号操作和逻辑规则来实现智能表达，代表就是人类自身的逻辑推理过程。

联结主义 是人工智能和认知科学中的一个重要理论范式，主张智能行为源于大量简单单元（如神经元）之间的连接与并行处理，代表就是DNN。

符号主义方式下，AI结果具备清晰、可读的逻辑推导过程、符合人类的因果推理认知，但是推理密集型的形式并不适合数据密集型的场景，对于大数据推荐（淘宝电商场景）、基于气象数据（如ERA5）的天气预测，并不适合人类“逻辑思维”范式去解决。

符号主义模式下商品推荐可以举个例子：

用户是男性、已婚二娃爸爸，年纪在35岁上下，生活在上海，年收入70万。让你给他推荐车。你会按照如下的范式完成推荐：

1. 用户是二娃奶爸，所以需要3排7座或6座大车来容纳更多的家庭成员；
2. 他是35岁的较年轻男性，对于新能源和智能驾驶的接受度比较高；

3. 他生活在上海，天气不会很冷，充电桩基础设施健全，可以优先把国产新能源电车纳入考虑范围；
4. 年收入70万，汽车预算可以定在30万左右，所以推荐理想i8。

联结主义方式下，AI结果属于盲盒状态，我们并不清楚经过DNN后隐层和参数到底对我们的输入做了什么，以及我们为什么会得到这样的输出。但DNN方式就是通过网络深度、神经元连接的复杂性、激活函数的非线性表达增强，配合上大规模的训练数据，实现了从样本中自动学习复杂模式的能力。

联结主义模式下上述推荐案例的实现方法，以简单的DSSM双塔结构为例：

假设他是一名淘宝用户：

1. 把用户画像表（包括上述人群特征）、用户订单表衍生字段、用户浏览行为表衍生字段进行向量化表达和拼接，作为用户高维表征；
2. 然后基于表征向量计算他和其他用户的cosin相似度，找出最相似的其他用户；
3. 根据相似用户的购车偏好给他推荐汽车，可能是问界M7。

因为考虑了更多的特征信息、并且基于大规模人群行为匹配，所以推荐结果可以做的更细致的偏好发掘、让推荐结果千人千面。


其实这两种模式一直在做融合性应用探索：

例如，结合知识库向量检索的RAG架构，是一种典型的Neuro-vector-symbolic Integrative Intelligence。其中，通过query做知识库向量检索获取相关文本信息，是一个典型的VSA（Vector Symbolic Architecture）架构，然后文本信息拼接到上下文里输入大模型；而知识图谱则是更典型VSA结构，它可以进一步表征出信息中的符号逻辑关系，然后通过高维向量转换，实现复杂结构和关系的紧凑性、情景化表达。

召回到的信息在拼接到LLM Insturct符号输入后，会完成一个由symbo向vector的转换，然后经过FFN后按symbo范式的结果返回，实现从vector向symbo的逆转换。所以除了知识检索、图召回外，LLM本身也是通过可计算的向量化（computable vectorization）实现联结主义（connectionist）与符号主义（symbolic）范式之间的融合。

3. 不同的方法如何选择？

Transformer架构确实在统一所有AI任务场景，LLM是Transformer架构在NLP场景下的一个具体实现形式。它本质上是基于token形式的回归预测模型，预测结果的备选范围也就是整个token vocabulary。



所以，“数字”在LLM模型中只是一个letter token，数字66和6的区别是2个还是有1个id=21的token，而不是difference（差分）=60。本质上，大模型不是在做calculation，而是凭借数感（i.e.学习到的统计分布规律）做predict。所以我们看到大模型做AIME这类重思维的数学竞赛题已经超越人类，但简单的加减乘除运算却始终存在错误。

下面是一个让Qwen3-235B-A22B-Instruct从表格里数数的简单例子：

【问题】

事实表介绍:商户人群画像表

shop_id:1071503

单个指标统计周期:30d

统计时段: [20250701, 20250731]

是否在统计时段ds_filter内部聚合求平均: True

数据:

<同行TOP10%平均>

dim_name	dim_value	差评数 (数)	评论数 (数)
人群	小镇年轻低产	nan	0.29
人群	都市白领	0.8484	7
人群	小镇土豪	nan	
人群	都市中老年低产	nan	0.96

【回答】

我们来一步一步分析这个问题。

问题:

<同行TOP10%平均> 表格中**第23行第6列**是什么值?

步骤 1: 确认表格范围

你提供的数据是一个名为 <同行TOP10%平均> 的表格，内容是按行排列的。我们需要找到：

- **第23行**（从表头之后的第一行数据算起，即第一行数据是第1行）
- **第6列**（列从左到右数）

步骤 2: 确定列名和列序号

表格的列头如下（共8列）：

dim_name	dim_value	差评数 (数)	评论数 (数)
----------	-----------	---------	---------

人群	学生	0.6677	11.4
人群	都市年轻低产	0.1033	
人群	未知	0.1	
人群	年轻妈妈	0.192	
人群	都市中产	0.1933	1
人群	小镇中老年	nan	
人群	小镇年轻低产	nan	0.29
人群	都市白领	0.8484	7
人群	小镇土豪	nan	
人群	都市中老年低产	nan	0.96
人群	学生	0.6677	11.4
人群	都市年轻低产	0.1033	
人群	未知	0.1	
人群	年轻妈妈	0.192	
人群	都市中产	0.1933	1
人群	小镇中老年	nan	

1	2	3	4
---	---	---	---

所以，第6列是“订单总价(分)”。

步骤 3：数第23行数据

我们现在从第一个数据行开始数，忽略表头。

每一行数据格式为：

▼

复制代码

| 人群 | xxxx | ... |

我们将逐行计数，注意：**重复的数据行也算在内**。

我们来列出前23行数据（只看 dim_value 和关键字段以便定位）：

行号
1
2
3
4
5
6
7
8
9
10
11
12
13

人群	小镇年轻低产	nan	0.29
人群	都市白领	0.8484	7
人群	小镇土豪	nan	
人群	未知	nan	r
人群	小镇土豪	nan	r
人群	小镇年轻低产	nan	r
人群	都市白领	1.5	3
人群	学生	1.5	4
人群	都市年轻低产	nan	
人群	小镇中老年	nan	r
人群	都市中产	nan	:
人群	年轻妈妈	nan	r
人群	都市中老年低产	nan	
人群	都市白领	0.8484	7

其中有公式如下：

均单笔补贴金额=总补贴金额/有效支付订单数

下单率 = 有效支付人数/店铺曝光uv

<同行TOP10%平均>表格中第23行第6列是什么值

14
15
16
17
18
19
20
21
22
23

第23行是：

人群	小镇土豪	nan	nan	1.2	7
042.4	3112.9	0.014			

步骤 4：取第6列的值

第6列是“订单总价(分)”，其值为：**7042.4**

最终答案

7042.4

【分析】

- 数到了第23行，但过程就像人看表格定位单元格一样，一个一个数过去，23可以，23000行呢？
qwen3-235b-a22b 推理模型的think也是类似操作：



2. 最终记录还是给错了，给的是第25行结果，因为第25行接近第23行，数行数对齐用的dim_value列也是“小镇土豪”，然后影响了predict结果。
3. 所以，总结起来，大语言模型不是真的通过位置索引定位列表记录的，而是一种符号预测形式。所以数据密集的计算场景并不适合LLM。

举一个预测应用的典型例子，就是天气预报场景：

古人没有数学基础、建模条件、传感器收集气象数据的情况下是如何预测天气的？

人们通过“现象观察 -> 总结抽象 -> 推演应用”，形成了“日晕三更雨月晕午时风”这类符号学经验，然后应用这些经验去做天气预测。这些推理有其合理性，尤其是在户外“荒野求生”时，精度虽低，无法准确定位一个区域的天气变化，但却能给出合理的预判，尤其是在小地理环境下，例如一条山谷、一片森林中，虽然不能提前很早预测天气变化，但却能辅助人类快速做出近端天气变化的判断。

之后有了现代 **数值预测模型**，他是专家们精心设计的函数公式，然后基于大规模的气象数据和超级计算机，完成数值计算和基于计算结果的气象预测，预测窗口从数小时到数天，都成为可能。

近些年，从DeepMind的GraphCast开始，天气预测又从传统的重模型结构设计的 **数值预测模型** 发展到了重数据和训练的 **深度学习模型**，其后华为的Pangu大模型、上海人工智能实验室的Fengwu大模型，都是AI和传统大规模数据、高密度计算预测场景的成功融合。Pangu底层采用了Swin Transformer，Fengwu底层采用了Encoder-Decoder+Cross-Modal Fuser的Transformer，都在预测实效和精度上超越了传统 **数值预测模型**。

但即使应用了AI大模型，我们还是发现天气预报时长失灵，尤其是出现强对流天气时——因为大模型建模基础是大气中层的环流趋势，低空层的局部强对流天气，变化速度太快、相关数据缺失，是无法准确预测的。另外，气象模型也无法捕获更细粒度的天气走势，例如横断山区的气候、西双版纳雨林的气候……“一山有四季，十里不同天”，地理上的局部小气候是无法被基于宏观气象数据学习得到的气象大模型所表征的。最后，天气是一个混沌系统，初始状态的微小差异也会使大气环境的演变结果发生巨大差异，即大气的内在随机性。

其实股票市场、交易市场是和天气气候类似的系统，所以大的经济学模型虽然不少，但是并不能判断出一个企业或商家的成败，更不能预知“黑天鹅”，所以微观经济体的预测就会

4. LLM-Empowered Autonomous Agents实现的范式融合

LLM通过tokenizer+embedding实现了符号模式和联结模式的融合：

1. 通过token结构完成自然语言（符号表达）的向量化转换
2. 通过self-attention完成每个token的in-context representation（联结计算）
3. 通过softmax激活完成从向量到token的映射（符号表达）

这里将“输入”和“输出”统一到了更符合人类自然语言习惯的“符号表达”，将“推理计算”交给了高维非线性网络完成“联结计算”。所以，一方面Generative Model和人类的信息交互形式一致（符号式），更符合我们对于AGI的应用模式定位；一方面基于Transformer架构的深度学习模型能通过强大的模式发现与特征关系表达能力实现更好的 $f(\theta)$ 表达。

所以，基于对Language Model机制的理解，我们可以定位出来一个LLM的发展方向——强化符号推理，模拟人类逻辑化的工作方式。

我们在定义一个任务是否适合LLM时，只要想一下这个任务下的顶级人类专家是怎么做的，就能确定他是否适合LLM的任务范式。例如，一个钢铁领域的金融行研专家，他在对钢铁行业投资价值预测时的工作流程如下：

1. 确定研究目标和框架

- a. 确定研究问题核心：行业趋势分析？投资组合建议？某家钢铁企业的投资价值？
- b. 制定研究框架：宏观经济分析的维度重点，微观企业分析的维度重点

2. 数据收集和处理

- a. 行业数据跟踪：例如粗钢日均产量、螺纹钢价格、焦炭价格、铁矿石期货走势等
- b. 企业数据收集：企业财报、技改项目信息、电话会议纪要、股权变动信息等
- c. 相关政策和新闻监控：发改委和工信部关于钢铁产能的政策、环保政策、海内外进出口政策等

3. 分析建模

- a. 供需测算：建立钢毛利测算的数值模型（不是预测模型），例如：钢毛利 = 钢材销售价格 - (铁矿石成本 + 焦炭成本 + 焦煤成本 + 能源 + 人工 + 折旧)，寻找产量盈亏平衡点
- b. 周期判断：收集钢铁行业相关指数的时序数据，通过SAS\R\SPSS等工具，完成向量回归、因子分析，对行业趋势做预测；完成对应关系分析、典型相关分析，对影响企业的重要因素做定位。
- c. 估值分析：通过PE、PB、EBITDA等指标计算结果比较历史和同行表现，确定当前状态

4. 实地调研与专家访谈

宏观数据会掩盖很多微观问题，数据的收集过程也可能存在失真，通过实地考察和专家咨询了解真实的行业现状

5. 输出研究报告

如果要让AI完成这一整套行研流程，我们需要怎么设计？


其实这是一个典型的智能体工作流程。我们将上述人工流程和智能体执行流程做个类比：

1. 上述行业报告生产中的“智力核心”是研究员，对应的智能体工作流的“智力核心”是LLM（更具体的是LRM），整个流程的设计、推进、响应、优化都是由研究员（/LRM）主导的。
2. 统计数据是从行业门户网站、政府单位、交易所渠道获取，研究员（/LRM）并不关心他们如何收集统计这些数据。
3. 研究员（/LRM）首先基于专业公式（也是一种数值模型）进行指标计算和逻辑推演，这种计算是通过excel、财务软件等工具完成的；
4. 研究员（/LRM）根据序列数据、面板指标，通过SAS/R实现通用的经济学统计建模（如VAR、PCA等），得到具有统计意义的分析结论，更准确的定位企业现状和发展趋势；
5. 研究员（/LRM）根据现实反馈（实地调研）或人工反馈（专家反馈）进一步优化自己的研究结果；
6. 研究员（/LRM）综合上述信息，撰写行研报告。

要实现如上所述的整个智能体流程，我们需要做什么呢？

从早期RaAct结构和langchain开发框架结合形成的 predefined execution workflow 到如今 DeepResearch为代表的 Autonomous and adaptive execution，以LLM为核心的智能体应用，也从工程为主的组装模式变化成工程为辅的一体化模式。

ReACT workflow



LLM-Empowered Autonomous Agents




Fig. 1. Elements of LLM-empowered Autonomous Agents (LAAs): Large Language Models (Neural Sub-System), Agentic Workflows (Symbolic Sub-System), and External Tools

智能体的推理过程包括2个核心模式：

1. 通过评估和规划进行推理

指的是智能体通过迭代式地制定计划（plan）、评估进展（reflect）、调整策略（refine），从而有效分解问题直至完成任务的能力。像“思维链”（Chain-of-Thought, CoT）、ReAct 和提示分解（Prompt Decomposition）等技术，都是旨在通过将复杂任务逐步拆解，提升模型进行战略性推理能力的方法。这类推理属于宏观层面，强调通过迭代推进，并综合考虑每一阶段的结果，确保任务被正确完成。

2. 通过工具使用进行推理

关注智能体有效与环境交互的能力，包括判断应调用哪些工具，以及如何构建每一次调用。这些工具使智能体能够获取数据、执行代码、调用 API 等。这种推理能力的核心在于正确执行工具调用，而非对调用结果进行深入反思。


这2种模式，前者的代表是DeepSeek-R1这类LRM，后者的代表是Kimi K2这类Instruct Model。目前这2种模式并没有充分绑定（DeepResearch、Claude Code可能实现了2种模式融合了），大多数时候我们是按“推理模型”和“智能体”2条独立的路线在开发应用。而在我们垂域，前者是 EBM-R1 后者是 EBM-DeepAnalysis-Agentica。

但是，融合2种模型的Autonomous Agents我们还没有完全达成，EBM-DeepAnalysis-Agentica更多的是将之前的react workflow内化，并且消除了人工prompt对问题执行的干预，带来推理空间的扩展，智能体可以实现更广泛的解空间搜索（这里搜索的本质，还是“符号学”的推理模式）。

那么所谓的融合模式是什么？为什么 EBM-DeepAnalysis-Agentica 还属于模式2？

1. 训练上：训练对象是一个完整的、连续的Trajectory，无论SFT还是RL，训练目标都需要咬定端结果的。
2. 数据上：Trajectory数据的仿真程度决定了Agent的解决模式，尤其是SFT阶段（冷启动和解决范式学习），会对后期RL的解空间搜索模式定型。如果你的Trajectory只是指标拆解计算，那训出来的agentic RM也就是指标计算器；
3. 表现/推理上：agentic RM的Trajectory推进模式不是单向链式结构，而是类似ResNet一样的残差（residual）连接结构，每一步的解决始终会回到总目标的对齐上，也因为这样的解决范式才能让智能体多视角、跨视角分析，而不是一步一步串行推理，然后对当前状态reflect后refine下一步操作，这种模式在订机票这类任务型SOP中可以起效（单指标分析），但距离上述行业报告的实现还有很长的距离。

Deep (Re)search Capabilities by Quadrants



* deep / shallow: how much each system iteratively search to acquire new information
* handcrafted / trained: how was the system or the model been tuned or trained.

外卖经营场景下的智能体定位

外卖经营场景下的智能体定位是“经营智能体”——实现从“辅助BD”到“辅助商家”再到“店铺托管”的演进。

那我们看看，现实中黄海葵这些外卖商户代运营公司是怎么做到“店铺托管”的？

1. 诊断：

- 完整的从多个渠道获取到店铺各种数据现状
- 看商圈里同品类top店情况（营业时长、高峰营业市场、招牌菜、套餐、定价、活动设置等）
- 结合店铺自身线下情况（例如本身卖的好的菜品）制定运营计划，例如看能否做线上小份菜、一人食、套餐等，做爆品打造。

2. 定价：精算，咨询商家第一阶段以订单增长为主还是要报利润，堂食和外卖占比，出餐能力，请员工多少，投多少商业化，投多少营销补贴

3. 营销：结合诊断和定价的营销设置

4. 商业化：实时操盘，根据当前在前端的排名情况即时操作，完成动态的商业化类设置及投放

5. 消费者管理：差评管理/IM回复/评分维护

6. 节庆一站式设计：动态的时令菜单建议/设计图维护

7. 持续性的用户维护：商户咨询，咨询维护等。

在整个代运营过程中，并不是预测单量为核心，而是以归因诊断和因果推理为基础，如果能在SHAP分析之后接入Uplift预测，这已经达到数据挖掘+数据智能专家的水准了，一般的代运营专家也只是做到n朴素的比较性逻辑推理——一种类似于控制变量分析的方法，通过观察好坏店铺指标统计上的差异，定位显著差异点，然后进一步分解差异点，如果定位出的叶子问题指标符合垂域经验（逻辑自洽），就完成了一次从现象到问题的定位，然后也是基于垂域经验映射到具体的优化操作。

因为整个过程基于符号模式，所以优化操作和问题指标之间并不具有统计意义上的强因果支撑，所以优化操作对象虽然和问题相关，但并不形成必然的因果关系，因此代运营专家上线某个优化策略后一般是观察一周，然后根据线上反馈再调整。

这里的整个过程也是一种现象指标输入到执行动作的预测过程，但这边的“预测”核心是“归因分析”、“因果推理”、“影响预估”，并不需要实际去预估不同状态下的具体订单量。

那什么情况下我们特别关注实际的订单量预测？

暂且不谈投资市场，一般重视订单预测的场景往往关系到资源的有效布局，例如淘宝电商、物流、客服场景，流量的预测关系到资源的有效分配和利用，商家根据618或双11等电商大促节点提前备货，物流根据大促活动预估可能的外卖订单波动然后提前准备配送人力，客服根据618或双11等电商大促节点的预估订单量提前准备客服路由规划。

上述场景中，订单量预测结果都是作为“自变量”来影响资源运筹安排这一“因变量”，如果配送人力跟不上会出现超时率暴涨、如果客服路由资源没到位会导致FRT（首次响应时间）暴涨、备货不充分会导致商家错过双11流量红利，这些都会导致业务损失（用户体验受损、商家营收受损、平台营收受损、公司名誉受损）。所以，在这些业务场景中，我们会关注并且执着于“订单预测/收入预测”。

但回到我们的智能体模型面对的问题场景：

通过分析商家数据，包括商家基础画像、商家经营画像、竞对画像、商圈画像、外卖经营环境画像（包括自然、政策、经济、社会舆论），基于归因分析和系统性推理，定位出影响当前商家经营结果的因子，然后基于因果推断、重要性影响、长期推理，为商家提供针对性的改善建议，并在统计意义上验证商家经营效果的改善结果。

上述场景，“订单量”并不牵扯到任何“资源运筹”，所以我们并不需要知道具体的订单量是多少。我们更关心的是影响商家经营结果的“因子”是什么？这些因子和结果之间存在什么具体的“因果关系”？然后定位清楚这些后，我们就可以直接指导商家的日常经营；更进一步，我们可以做到代商操作。


无论是做订单量的数值预测，还是围绕订单量目标做归因推理，都属于算法预测形式，这也恰好对应了预测的2种形式：

第一种模式是时间序列预测（Forecasting）：用过去的的数据去预测未来结果，属于多变量回归范畴，代表模型如VAR, LSTM, CNN等。

第二种模式是状态估计或滤波（Filtering）：根据当前状态（当天近一周统计指标也属于当前可见的状态信息）来预测结果，属于条件概率预测范畴，代表模型如状态空间模型（卡尔曼滤波）、HMM。

两种模式的根本区别在于目标：预测模式关注未来值的外推，基于历史依赖性；估计模式关注当前值的“去噪”或推断，强调实时数据融合和状态更新。

第一种模式：太多了，从统计/机器学习到深度学习，arima、STL、LSTM、MQCNN再到基于transformer架构的各种transfer learning变体，这里不做赘述，到了transformer架构的变种，核心还是跨域编码的对齐，类比Blip-2框架：



第二种模式：从当前多变量观测中估计当前隐藏状态或校正噪声，常用于实时系统。主要方法包括：

- 状态空间模型（SSM）：如卡尔曼滤波（Kalman Filter），通过状态方程和观测方程融合当前数据，估计当前状态值（例如，位置或温度），适用于线性高斯系统。
- 隐马尔可夫模型（HMM）：建模观测序列与隐藏状态间的概率关系，用当前观测估计最可能当前状态1。
- 深度学习扩展：RNN或LSTM可用于序列滤波，但需结合特定结构（如粒子滤波集成）处理实时估计1；信息缺失深度滤波的详细架构。

估计模式强调实时性：输入当前多变量数据后，算法立即输出估计值，依赖贝叶斯更新或概率推断，而非历史趋势建模。

这个LLM的底层逻辑是一致的。

从“垂域推理模型”到“经营智能体”的实现路径

1. 到Experience中去

因为 [Era of Experience](#) 这篇文章，会有人认为：只有海量的真实环境数据才能突破以人类为中心的AI系统边界。但是我们要清楚，这里的“experiential data”的主体是agents：

Our contention is that incredible new capabilities will arise once the full potential of experiential learning is harnessed. This era of experience will likely be characterised by agents and environments that, in addition to learning from vast quantities of experiential data, will break through the limitations of human-centric AI systems in several further dimensions:

- Agents will inhabit streams of experience, rather than short snippets of interaction.
- Their actions and observations will be richly grounded in the environment, rather than interacting via human dialogue alone.
- Their rewards will be grounded in their experience of the environment, rather than coming from human judgement.
- They will plan and/or reason about experience, rather than reasoning solely in human terms

所以，在向 **Experience** 数据消费形式转型的过程中，核心在于Agent本身与环境的交互，然后从环境反馈中汲取奖励，不断优化自身。这里的整个过程是learning from experience。

但如果我们误认为这种experience是指的人类在生产环境中的真实数据，一种可能的情况是我们会带着我们自己的“认知偏见”去从环境中提取我们认为重要的信息作为上下文输入给agent，然后让agent学习受到我们“偏见”潜移默化的影响——我认为这些店铺信息很重要，我认为这些活动就应该影响商家经营结果。

所以，Agent的训练应该回到Trajectory这种Agent Experience Data的仿真上来，让Agent从和环境的experience中获取样本、也从和环境的experience中进化自身，而不是按人类的数据去off-policy。

2. 垂域经营智能体的差异在哪儿？

视角	差异点	说明
数据理解	人人都知道通过mcp查数/查知识—— 但饿了么的业务还需要关注什么特定指标和数据？	遇到数据需求走工具池里的查数工具，遇到业务知识走知识库，这是所有具备Agent应用模式的LLM都会做的事情。 但垂域对开源的差异化优势，在于结合垂域知识正确且合理的调起工具。这边的垂域知识也包括了业务规则、方法论等，因为垂域知识的差异导致了同一问题在垂域和开源下的“解空间”差异，所以垂域知识对齐后的LLM： 一方面 ，可以更准确的理解垂域下的数据和指标（例如，确认商家能不能享受金牌商家权益，需要查看的是15分钟的有效回复率（Declarative knowledge），而回复率需要大于95%（Procedural Knowledge））； 一方面 ，也大幅提升了token效率，不会出现大量与垂域目标无关的假设。

分析 方法	参考着数据，人人都会写全面、详尽的专业分析报告—— 但饿了么自己的业务是怎么做分析的？	通用的企业管理学分析方法和宏微观经济学模型，在世界知识里都是充分公开的，有模式实现效果的好坏之分（应用上述专业方法做分析的模式——dsk-r1的表现比qwen-235b-a22b好），但没有模式的对错之别。 一方面，垂域特有的指标/概念定义（例如店铺分的计算构成）和通识知识的差异化，必然会影响我们分析视角的选择和规划； 一方面，垂域特有的方法论、分析策略等，也为垂域差异化的分析模式提供了偏好对齐的方向。 <table><tr><th>标题</th><th>方法定位</th></tr><tr><td>TRUST 查看 +</td><td>饿了么经营分析模型</td></tr><tr><td>SEAT</td><td>饿了么经营分析模型</td></tr><tr><td>iSEE</td><td>饿了么经营分析模型</td></tr><tr><td>斗金推广（CPC）使用方法</td><td>饿了么经营工具应用策略</td></tr><tr><td>运营前数据现状模板</td><td>饿了么经营分析模型</td></tr><tr><td>体检报告模版</td><td></td></tr></table> 开源和垂域对同一业务问题的分析方法偏好，也会导致分析过程和结论上的差异，尤其是开放性的业务问题上，例如诊断报告、营销建议。 参考： Orchestration-Domain-Method-Source_for_	标题	方法定位	TRUST 查看 +	饿了么经营分析模型	SEAT	饿了么经营分析模型	iSEE	饿了么经营分析模型	斗金推广（CPC）使用方法	饿了么经营工具应用策略	运营前数据现状模板	饿了么经营分析模型	体检报告模版	
标题	方法定位															
TRUST 查看 +	饿了么经营分析模型															
SEAT	饿了么经营分析模型															
iSEE	饿了么经营分析模型															
斗金推广（CPC）使用方法	饿了么经营工具应用策略															
运营前数据现状模板	饿了么经营分析模型															
体检报告模版																
执行 建议	看数分析之后，通识建议人人都能给—— 但饿了么了自己的业务是如何处理和执行的？	所有落到生产上的建议执行手段和问题牵引策略，都必须来源实际生产；没有垂域生产环境和营销等工具的掌握，LLM是无法为特定商家在特定状态下给出具体、可行的动作建议的，也就无法真正意义上实现托管。 大而泛的策略建议，例如“关注用户差评回复效率”、“推出针对老客的复购优惠活动”等，开源也能结合数据给出来，但只有垂域模型知道“CPC要怎么投放才适合当前状态下的店铺”。 如果期间再涉及到营销等工具的自动化执行/配置，开源模型就更无法像业务微调的模型那样做到精确适配了。														

3. 阶段划分

基于个人的理解，我将智能体分解成了如下4个阶段：

Level1-ReAct

智能体等级说明：

能力	范围	形式	
可读	- 问题本身 - 过去可查	纯文字语句	问题回

问题样例：

	问题	答案
样例	商家（shopId: xxx）昨天销量最好的菜品（当前时间：2025年7月4日）是否属于当前的商圈热销菜top5（注：无需考虑菜品尺寸或规格的不一致）。	是
分析	一个点的问题。需要通过数据查询或内部信息检索，获得回答问题所必须的事实性信息。 解决比Plan更简单、明确的问题，不依赖自发性的推理、下钻、发散。	答案可以明确客观，可被verify

Level2-Plan


智能体等级说明：

能力	范围	形式	
可读	- 问题相关 - 过去可查	图文综合报告	问题回

问题样例：

	问题	答案
--	----	----

样例	我7月份的营业时间需要怎么优化？	1. 查询7月份当前的营业时间 2. 查询同商圈竞对的营业时间 3. 7月份的行业消费趋势—— 4. 商家基本信息（品类、城 5. 给出综合建议
分析	一个面的问题。需要针对某个维度，形成基础的分析框架（original plan），然后逐步执行下钻，在和垂域环境连续交互的过程中，动态规划下一步的执行动作。 结果上类似代运营，但具备自主查询带来的更全面的垂域环境感知域，动态规划执行带来的更深入、多样的单视角分析效果。	LLM-as-a-judge + Constitution 查关键过程信息，例如店铺本对营业时间。 参考： 【代运营应用场景】模型



例如：

当前的代运营AI分析报告： #新疆烧烤·阿力木特色烤羊肉#门店经营体检报告

Level3-Orchestration

智能体等级说明：

能力	范围	形式
- 可读 (可写)	- 问题扩散的世界信息 - 过去可查、当前可见	- 图文综合报告 - 图文交互（用户确认后自动执行）

问题样例：

	问题	答案
样例	我7月份的营业时间需要怎么优化？	1. 查询7月份当前的营业时间 2. 查询同商圈竞对的营业时间 3. 结合7月份的一般消费趋势 4. 单位时间成本 5. 不同时段订单量参考预估 6. 利用掌握的盈亏平衡分析理 7. 实时社会热点：结合最近的 8. 实时经济环境：国家关于线 9. 实时行业环境：相关单位或闪购和美团的补贴活动、国 10. 通过Python执行STL趋势分断、数据可视化，分析闪购响预估 11. 给出全面建议

分析	和Plan解决的 <u>问题没有变化</u> ，但对问题的思考和环境感知的深度和广度都有了显著的提升，除了垂域环境感知，感知范围进一步扩展到实时社会热点、政策法规、经济动态，并主动利用专业理论、专业算法，借助coder能力，实现“理论”、“数据”、“推理”的3方面整合，输出专业管理咨询公司级的行业报告。	待定，可能只有BD+代运营的“双
----	--	------------------

智能体等级说明：

• 可读 • 可写	• 问题扩散的世界信息 • 过去可查、当前可见、未来可检	• 图文交互 • 持续跟踪反馈
--	---	--

问题样例：

	问题	答案
样例	改善我的7月份营业额	一个月后（或某个协定时间点合营业状况更健康。
分析	在Orchestration的基础上，由单点推理变成时序上的持续推理，和内外环境持续交互，获得反馈后，动态更新和自进化，实现生产环境下的持续学习。	一次Orchestration的结果，可量的不充分、公式计算的理想摩擦或规则限制）、有偏数据等，都可能造成理论推理结果距很大，需要及时感知随着动进，归因分析的预估结果是否有，及时reflection，调整新的这个过程需要围绕端目标（上述态优化，所以模型训练时也需

BTW：仿真环境有2个好处：

- 1.应用基线拉高，更容易被环境中的attendee所接受，改善从环境持续学习的效果（不然很容易用户会被‘逆向教育’）
- 2.加速学习进化（参考遗传算法）

实践之路


1. 定位

无论何时，推理模型深度的探索都无外乎3个点：造数、训练、评判。

核心工作：数据合成

造数是一切的基础，上面也提到了，整个 LLM-based Autonomous Agents的能力核心，首先是模拟样本，你能模拟出来的冷启动样本的解题难度、分析范式，定型了RL优化的范围。这点在EBM-R1的实践中已经有直观的认知，所以这边不再赘述。

数据合成上，从上述智能体应用视角出发，去合成所需要的应用分析数据——数据是应用于drop-in model还是agentic experiences，并不影响数据源头的生产，尤其是Q-A的设计。



进化基础：结果评判

不同于过去纯粹的verifiable ground-truth的视角，如果想实现上述智能体的进化，我们不可避免的需要干预推理范式、方法的正确性，前期包括推理、指令遵循在内的通用基础能力已经通过具备verifiable ground-truth的样本学习达成，如果要在回答效果和质量上获得相对开源counterpart的差异化的优势，没有照搬raw data这些偷懒的途径——需要我们根据上述合成数据的思路去配套生产评判标准。

例如，一套validation principle list、基于专家经验的check-list for AI。

为了实现这个目标我们甚至可以构建一个垂域agent，通过查数和知识，来cross-validation结果的逻辑合理性。例如，他知道去查询同商圈竞对的表现期望值去评估当前店铺结果数据的合理性。

技术基础：递进式训练

无论大家承不承认，观点上赞同不赞同，EBM-R1和EBM-Agent-R1的当前实践，都是在沿着类似递进式学习（类似课程学习）的模式进行：SFT打基础，RL优化表现；先“模仿”再“创造”；简单问题到复杂问题，动态学习。

训练模式并没有发生什么大的变化，也不是核心差异的来源，这边就不做赘述了。

2. 分工

时间范围：至9月30日

工作范围：只涉及方向不涉及具体实现，更不涉及目标函数、梯度优化器选择等技术细节。

本文只讨论大的方向，所以每个维度的具体实现细节，需要单独启动方案。

方向	维度	工作阶段	工作内容细节	负责人
----	----	------	--------	-----

推理模型：垂域推理基础已经构建完成，进一步实现垂域业务场景的特化。

专业分析轨迹数据生产	prep	基于plan和orchestration的模式描述，去定义解题范式。 首先，根据解题范式的需要，定位数据合成的信息来源： 1. 垂域知识 (p0) 2. 垂域数据 (p0) 3. 开发域分析方法 (p0) a. 管理学 b. 金融学 c. 多元统计分析 4. 垂域分析方法 (p1) a. 分析模型/方法论 b. 工具策略 5. 外部行业趋势信息 (p2) 6. 外部社会经济热点信息 (p2) 其次，上述多维数据的分析轨迹组装。
解决范式学习	sft	SFT阶段，注入行业领域专业分析模式（参考dsk-r1和qwen3在回答分析类问题的区别） 除环境查询工具之外的解决能力工具掌握（这里专指python code工具）。
端结果的校验评估	rl	这里分2层： 1. 解答范式：参考Plan和Orchestation解答范式，通过AI方式做check-list。 2. 答案正义性：上述样本问可能无法有效判断正确性，但可以通过AI方式实现“正义性”校验，即对hallucination问题做识别评判、异常数值的预测等。
对回复期望的优化	rl	就“经营智能体”在经营诊断分析场景下的问答表现期望，设计配套该批数据的特定奖励机制。

@...

	专业工具的应用能力实现	sft	这里只关注python代码的应用效果，实现如下功能： 1. 通过sklearn等核心工具包，完成基本的机器学习建模和分析的能力； 2. 利用matplotlib、seaborn等核心工具包，完成数据的可视化呈现； 3. 自行编写建议calculation工具完成推理过程的计算应用或校验。
自动化智能体	对接智能体开发组，做上述工作的迁移应用		

参考

• 文献

[1] Haoyi Xiong, etc. *Converging Paradigms: The Synergy of Symbolic and Connectionist AI in LLM-Empowered Autonomous Agents*. arXiv preprint arXiv:2407.08516, 2024.

[2] OpenAI. Deep Research System Card. URL: <https://cdn.openai.com/deep-research-system-card.pdf>

[3] Malcolm L. Wolff, Shenghao Yang, Kari Torkkola, Michael W. Mahoney. *Using Pre-trained LLMs for Multivariate Time Series Forecasting*. arXiv preprint arXiv:2501.06386, 2025.

[4] David Silver, Richard S. Sutton. *Welcome to the Era of Experience*. URL: <https://storage.googleapis.com/deepmind-media/Era-of-Experience%20/The%20Era%20of%20Experience%20Paper.pdf>

[5] OpenAI, *Language Models are Few-Shot Learners*. arXiv preprint arXiv:2005.14165, 2020.

[6] Shunyu Yao, etc. *REACT: SYNERGIZING REASONING AND ACTING IN LANGUAGE MODELS*. arXiv preprint arXiv:2210.03629, 2023.

[7] Craig M. Parker, John Liman, Paula M.C. Swatman. *TRECS: Developing a Web-based e-Commerce Business Simulation*. URL: <https://citeseerx.ist.psu.edu/document?repid=rep1&type=pdf&doi=ca1e594efc660dd18844d375031b540ec1124fae>

[8] Tula Masterman, Sandi Besen, Mason Sawtell, Alex Chao. *The Landscape of Emerging AI Agent Architectures for Reasoning, Planning, and Tool Calling: A Survey*. arXiv preprint arXiv:2404.11584, 2024.

[9] Zhijing Jin, Jiarui Liu, etc. Can Large Language Models Infer Causation from Correlation? *arXiv preprint arXiv:2306.05836*, 2024.

- 站点

[21] *The Differences between Deep Research, Deep Search, and Just Search*. URL: <https://leehanchung.github.io/blogs/2025/02/26/deep-research/>

[22] [多特征变量序列预测\(七\) CEEMDAN+Transformer-BiLSTM预测模型](#)

[23] [时间序列多步预测的原理](#)

[24] [时间序列预测模型的工作原理](#)

[25] [LLMs Can't Calculate: Why You Should Use Tools for Math](#)

[26] [Generalizing an LLM from 8k to 1M Context using Qwen-Agent](#). URL : <https://qwenlm.github.io/blog/qwen-agent-2405/>

[27] [nvidia: Build an AI Agent for Enterprise Research](#)

[28] [Generalizing an LLM from 8k to 1M Context using Qwen-Agent](#)

[29] [Kimi K2: Open Agentic Intelligence](#)

[210] [Gorilla: Large Language Model Connected with Massive APIs](#)

[211] [NexusRaven-V2: Pushing The Boundaries of Open Source Function Calling Models](#)

- 内部文档

 [官方代运营2.0探索](#)

Appendix

时序预测之多元回归分析的底层逻辑

参考书：《计量经济学分析方法与建模》高铁梅

除非有建模环境，实际生产中的数据，并不能纯粹的刻画出所谓自变量、因变量、协变量（i.e.控制变量）数据。

首先我们先定义清楚建模中的变量含义：

1. 自变量：研究者主动操纵，引发因变量发生变化的因素或条件
2. 协变量：独立于自变量的解释变量，它会影响因变量，但不为研究者所操纵，然后我们会在研究自变量和因变量关系时通过统计手段对它们加以控制（例如固定值过滤样本），以清晰的定位出自变量和因变量间的二元关系。例如我们在研究人口的男女分布以及寿命差异时，会固定时间，时间就是一个协变量，从古代到现代，人群特征肯定是存在显著差异的，但我们在当前的男女人口研究中只关心性别，不关心时间。

到底什么是置信区间？

真实分布样本总体的平均值尽管未知，但是是确定性的，不存在它有多大概率（95%）落在某一区间的说法，或者说它其实是以100%的概率位于某点处，只是我们不知道该点是多少，于是我们需要去估计一个区间。

如果“满意度均值是 $80\% \pm 5\%$ ，置信度95%”，然后认为总体均值落在 $[a, b]$ 之间的可能性是95%，这是典型的错误理解。

1) 样本满意度均值是80%，这是用样本对总体的点估计

2) 点估计的范围是区间（75%，85%）

3) 如果用类似的方法，重复抽取大量（样本量相同）样本时，产生的大量类似区间中有些会覆盖真正的总体参数值（即总体满意度），而有些不会，但其中大约有95%会覆盖真正的总体参数值。

也就是有多大概率你的采样样本能刻画出真实分布，这里强调的是采样分布对真实分布的刻画，所以需要紧紧围绕概率密度函数/分布函数属性。